

Predição de Hospitalização em Casos Confirmados de Dengue: uma Abordagem de Aprendizado de Máquina Aplicada a Dados do SINAN/DATASUS

Geovanna da Silva Lima ¹ Pedro Henrique Mansano Fernandes ¹
Priscila Raquel Herculano Correia ¹
Leandro Zerbinatti ¹

¹Faculdade de Computação e Informática (FCI)
Universidade Presbiteriana Mackenzie São Paulo, SP – Brasil

<geovanna.lima@mackenzista.com.br>
<pedrohenriquemansano.fernandes1@mackenzista.com.br>
<priscilaraquel.correia@mackenzista.com.br>
<1172260@mackenzie.br>

2026

Resumo

A dengue constitui uma das arboviroses de maior relevância epidemiológica no Brasil, caracterizada por surtos sazonais que impõem sobrecarga recorrente aos serviços de saúde pública. A identificação precoce de pacientes com maior propensão à hospitalização representa um desafio relevante para a gestão clínica e hospitalar, sobretudo em contextos de alta demanda assistencial. Este trabalho propõe a aplicação de técnicas de Aprendizado de Máquina para a predição de hospitalização em casos confirmados de dengue, utilizando exclusivamente variáveis disponíveis no primeiro atendimento médico – dados demográficos, sinais clínicos e comorbidades pré-existent. Foram utilizados dados públicos do Sistema de Informação de Agravos de Notificação (SINAN/DATASUS), referentes a notificações de dengue no estado de São Paulo no ano de 2025. A análise exploratória evidenciou acentuado desbalanceamento entre as classes de interesse, com aproximadamente 4,7% dos casos confirmados resultando em hospitalização, o que orientou decisões metodológicas quanto ao tratamento dos dados e à seleção de métricas de avaliação. O processo de preparação dos dados contemplou a remoção de variáveis com vazamento de informação, o tratamento de valores ignorados e a amostragem estratificada do conjunto de dados. A etapa subsequente da pesquisa contempla o treinamento e a avaliação de modelos de classificação supervisionada, com ênfase em métricas robustas a cenários desbalanceados, como F1-score, recall e

AUC-ROC. Espera-se, como contribuição deste trabalho, um modelo estatisticamente fundamentado capaz de subsidiar processos de triagem clínica e de gestão de leitos hospitalares em contextos de vigilância epidemiológica da dengue.

Palavras-chave: Inteligência Artificial; Aprendizado de Máquina; Dengue; Saúde Pública; Classificação.

Abstract

Dengue fever constitutes one of the most epidemiologically relevant arboviral diseases in Brazil, characterized by seasonal outbreaks that impose recurrent strain on public health services. Early identification of patients with a higher propensity for hospitalization represents a significant challenge for clinical and hospital management, particularly in contexts of high care demand. This work proposes the application of Machine Learning techniques to predict hospitalization in confirmed dengue cases, using exclusively variables available at the first medical encounter – demographic data, clinical signs, and pre-existing comorbidities. Public data from the Notifiable Diseases Information System (SINAN/DATASUS) were employed, corresponding to dengue notifications in the state of São Paulo in 2025. Exploratory analysis revealed pronounced class imbalance, with approximately 4.7% of confirmed cases resulting in hospitalization, which informed methodological decisions regarding data treatment and evaluation metric selection. The data preparation process involved the removal of variables subject to information leakage, treatment of ignored values, and stratified sampling of the dataset. The subsequent stage of this research involves training and evaluating supervised classification models, with emphasis on metrics robust to imbalanced scenarios, such as F1-score, recall, and AUC-ROC. As a contribution, this work is expected to yield a statistically grounded model capable of supporting clinical triage and hospital bed management processes within dengue epidemiological surveillance contexts.

Keywords: Artificial Intelligence; Machine Learning; Dengue; Public Health; Classification.

1 Introdução

A dengue é uma das arboviroses mais relevantes para a saúde pública brasileira, apresentando picos sazonais que, em anos epidêmicos, geram sobrecarga significativa da rede de atenção à saúde. Transmitida principalmente pelo mosquito *Aedes aegypti*, a doença apresenta um espectro clínico amplo, que vai desde quadros febris autolimitados até formas graves, com sinais de alarme e risco de choque, o que exige da rede assistencial capacidade de triagem rápida e precisa. Em anos de alta incidência, o volume expressivo de notificações sobrecarrega unidades básicas de saúde, prontos-socorros e hospitais, tornando a priorização de casos um elemento crítico da resposta em saúde pública.

A identificação precoce de pacientes com maior risco de agravamento é um desafio recorrente, especialmente em cenários de alta demanda, nos quais a triagem eficiente pode reduzir a pressão sobre leitos hospitalares. Tradicionalmente, essa triagem depende fortemente do julgamento clínico individual, apoiado em protocolos e escores de risco construídos a partir de evidências agregadas, mas nem sempre validados para a realidade epidemiológica local. Nesse contexto, o crescimento da disponibilidade de bases de dados públicas de vigilância epidemiológica, combinado ao avanço de técnicas de Aprendizado

de Máquina, abre a possibilidade de complementar esse julgamento clínico com modelos preditivos construídos a partir de dados reais de notificação.

O uso de Inteligência Artificial na saúde pública tem se expandido nos últimos anos, com aplicações que vão da previsão de surtos epidemiológicos à priorização de pacientes em serviços de urgência. No caso específico da dengue, a possibilidade de antecipar, já no primeiro atendimento, quais pacientes têm maior propensão a evoluir para hospitalização representa uma contribuição concreta para a gestão de recursos assistenciais, sobretudo em municípios e regiões nas quais a oferta de leitos é limitada em relação à demanda gerada por surtos sazonais. É nesse cenário que se insere a proposta deste trabalho, que busca conciliar rigor metodológico na construção do modelo preditivo com atenção às limitações e implicações éticas do uso de dados sensíveis de saúde.

1.1 Justificativa

O Sistema de Informação de Agravos de Notificação (SINAN), mantido pelo Ministério da Saúde, disponibiliza publicamente dados reais e volumosos de notificações de dengue ([Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde e Ambiente, s.d.](#)), o que viabiliza a aplicação de técnicas de Aprendizado de Máquina a um problema de relevância prática e social. A construção de um modelo preditivo de hospitalização, baseado exclusivamente em informações do primeiro atendimento, tem potencial de apoiar decisões de triagem e alocação de recursos hospitalares.

1.2 Objetivos

O objetivo geral deste projeto é desenvolver um modelo de classificação capaz de prever a hospitalização de pacientes com dengue confirmada, utilizando exclusivamente variáveis disponíveis no primeiro atendimento médico. Busca-se, com isso, construir uma ferramenta estatisticamente fundamentada que possa, no futuro, subsidiar processos de triagem clínica, sem substituir o julgamento médico, mas oferecendo um indicativo adicional de risco baseado em padrões observados em um grande volume de notificações reais.

Para alcançar esse objetivo geral, o trabalho está estruturado em torno de quatro frentes específicas:

1. Obter e filtrar os dados de notificação de dengue do estado de São Paulo referentes a 2025, delimitando o escopo aos casos com classificação final confirmada;
2. Realizar uma análise exploratória para compreender o perfil demográfico e clínico dos casos, bem como o comportamento e o desbalanceamento da variável-alvo;
3. Preparar os dados para a etapa de modelagem, tratando valores ignorados, registros inconsistentes e eliminando variáveis que possam gerar vazamento de informação entre preditores e desfecho;
4. Treinar e avaliar modelos de classificação supervisionada, adotando métricas apropriadas ao cenário de desbalanceamento de classes identificado nos dados.

1.3 Opção do projeto

O grupo optou pela opção *framework*, empregando a biblioteca *scikit-learn* ([PE-DREGOSA et al., 2011](#)) para a resolução de um problema de classificação binária de

negócio/saúde, referente à predição de hospitalização em casos confirmados de dengue. A escolha por essa opção se justifica pelo fato de o projeto não demandar o desenvolvimento de um algoritmo de aprendizado de máquina do zero, mas sim a aplicação criteriosa de técnicas já consolidadas na literatura – como Regressão Logística e Random Forest – a um problema real, de relevância social, com dados públicos volumosos e de qualidade heterogênea.

Dessa forma, o esforço do grupo concentra-se nas etapas que mais impactam a qualidade final do modelo em um cenário de dados de saúde: a correta delimitação do problema, a análise exploratória cuidadosa, a preparação dos dados com atenção a vieses e vazamento de informação, e a escolha de métricas de avaliação adequadas ao desbalanceamento de classes observado. O uso do *scikit-learn*, biblioteca amplamente adotada tanto na academia quanto na indústria, garante acesso a implementações validadas dos algoritmos de classificação, bem como a ferramentas de pré-processamento, validação cruzada e cálculo de métricas, permitindo que o grupo direcione seus esforços para as decisões metodológicas do projeto em vez da reimplementação de algoritmos já bem estabelecidos.

2 Descrição do Problema e Dataset

Esta seção apresenta, de forma integrada, o problema de aprendizado de máquina a ser resolvido e a base de dados que sustenta a proposta. Primeiramente, delimita-se formalmente o problema de classificação, a variável-alvo e as variáveis explicativas consideradas válidas dentro do recorte temporal do primeiro atendimento médico. Em seguida, descreve-se a origem, a composição e o processo de análise exploratória e preparação do conjunto de dados do SINAN/DATASUS utilizado no desenvolvimento do modelo, de modo a evidenciar as decisões metodológicas que decorrem diretamente das características observadas nos dados.

2.1 Descrição do Problema

Trata-se de um problema de classificação binária supervisionada, no qual a variável-alvo é a ocorrência de hospitalização (campo HOSPITALIZ do SINAN, codificado como 1 = Sim e 2 = Não). As variáveis explicativas restringem-se a informações plausivelmente disponíveis no momento do primeiro atendimento médico: dados demográficos (idade, sexo, gestação, raça/cor), sinais e sintomas clínicos (febre, mialgia, cefaleia, exantema, vômito, náusea, dor retro-orbital, petéquias, entre outros) e comorbidades pré-existent (diabetes, hipertensão, doenças renais e hepáticas, entre outras).

A análise exploratória identificou um desbalanceamento relevante entre as classes: entre os casos confirmados de dengue no estado de São Paulo em 2025 com desfecho de hospitalização conhecido, aproximadamente 4,7% foram hospitalizados. Esse desbalanceamento é um aspecto central do problema e orienta tanto a preparação dos dados quanto a escolha de métricas de avaliação na etapa de modelagem, uma vez que a acurácia isoladamente não é uma métrica adequada nesse cenário.

2.2 Dataset: Descrição, Análise Exploratória e Preparação dos Dados

Os dados empregados neste trabalho são provenientes do Sistema de Informação de Agravos de Notificação (SINAN), disponibilizados publicamente pelo Ministério da Saúde por meio do Portal Brasileiro de Dados Abertos ([Brasil. Ministério da Saúde. Secretaria](https://brasil.ministerio-da-saude.gov.br/secretaria)
Campus Higienópolis: Rua da Consolação, 930 - Consolação - São Paulo - SP - CEP 01302-907

Tel. (11) 2114-8301 - www.mackenzie.br - e-mail: fci@mackenzie.br

de Vigilância em Saúde e Ambiente, s.d.). O escopo da pesquisa foi delimitado aos casos com classificação final confirmada – campo CLASSI_FIN igual a 10 (Dengue), 11 (Dengue com Sinais de Alarme) ou 12 (Dengue Grave). Cabe registrar que essa codificação diverge da constante na definição textual do dicionário de dados oficial do SINAN, que ainda referencia um esquema anterior (1 = Confirmado, 2 = Descartado), a codificação adotada neste trabalho foi validada diretamente na base de dados utilizada e é consistente com a documentação técnica sobre a evolução histórica dessa variável (OLIVEIRA, s.d.).

Após a aplicação desse recorte e a exclusão de registros com desfecho de hospitalização ignorado, obteve-se um conjunto de 733.633 casos válidos, dos quais 34.517 (4,7%) resultaram em hospitalização e 699.116 (95,3%) não. Esse acentuado desbalanceamento entre classes constitui um aspecto estrutural do problema, com implicações diretas sobre as decisões de modelagem. As variáveis clínicas de preenchimento obrigatório no formulário de notificação – como febre, mialgia e cefaleia – apresentaram integridade, ao passo que variáveis sociodemográficas como raça/cor e gestação registraram proporções mais expressivas de valores ignorados (13,7% e 6,5%, respectivamente). Observou-se ainda que pacientes hospitalizados tendem a apresentar idade superior à dos não hospitalizados, além de terem sido identificados registros de idade clinicamente implausíveis, decorrentes de inconsistências no preenchimento do formulário de notificação.

A preparação dos dados orientou-se pela exclusão de variáveis preenchidas apenas após a ocorrência do desfecho – como datas de internação, óbito e encerramento do caso –, de modo a evitar vazamento de informação entre preditores e variável-alvo. Complementarmente, valores ignorados em variáveis sociodemográficas foram tratados como categoria própria, em vez de descartados, preservando a integridade amostral do conjunto de dados; registros de idade implausíveis foram tratados como valores ausentes; e o conjunto final foi submetido a amostragem estratificada, seguida de divisão em conjuntos de treino e teste, de modo a preservar, em ambos, a proporção original entre as classes da variável-alvo.

3 Aspectos Éticos do Uso da IA e Responsabilidade no Desenvolvimento da Solução

Os dados utilizados neste projeto são públicos, disponibilizados pelo Ministério da Saúde por meio do Portal de Dados Abertos, sem identificação direta dos pacientes. Ainda assim, trata-se de dados sensíveis de saúde, o que exige cuidado redobrado quanto ao seu uso, mesmo em contexto exclusivamente acadêmico.

Um ponto de atenção ético relevante é o uso de variáveis sociodemográficas sensíveis – como raça/cor e gestação – como preditores do modelo. Embora clinicamente relevantes, essas variáveis podem atuar como proxies de desigualdades estruturais de acesso à saúde, e não necessariamente de fatores biológicos de risco. O grupo pretende avaliar, na etapa de modelagem, se o desempenho do modelo é equilibrado entre subgrupos demográficos, de modo a identificar possíveis vieses antes de qualquer conclusão sobre a utilidade prática da solução.

Por fim, destaca-se que um modelo preditivo de hospitalização deve ser compreendido como ferramenta de apoio à decisão clínica, e não como substituto do julgamento médico. Erros de classificação em contexto de saúde têm consequências assimétricas: um falso negativo (paciente de risco classificado como baixo risco) é potencialmente mais grave do que um falso positivo. Essa assimetria reforça a responsabilidade do grupo em comunicar claramente as limitações do modelo e em não recomendar seu uso como critério único de

decisão.

4 Resultados Esperados

A etapa de modelagem prevista para a continuidade deste trabalho contempla o treinamento e a comparação de modelos de classificação supervisionada – como Regressão Logística e Random Forest –, implementados por meio da biblioteca *scikit-learn*. Em razão do acentuado desbalanceamento identificado na análise exploratória, serão adotadas estratégias específicas de tratamento das classes, como a ponderação de pesos durante o treinamento e, se necessário, técnicas de reamostragem do conjunto de dados.

A avaliação dos modelos não se restringirá à acurácia, dado que essa métrica se revela inadequada em cenários de desbalanceamento pronunciado – um classificador que atribuisse trivialmente a classe majoritária a todos os casos atingiria aproximadamente 95% de acurácia sem qualquer capacidade preditiva efetiva. Serão empregadas, portanto, métricas mais sensíveis ao desempenho na classe minoritária, como F1-score, *recall* e AUC-ROC, com atenção particular ao *recall* da classe positiva, em razão do custo assimétrico associado a falsos negativos em contextos clínicos: a não identificação de um paciente com risco real de hospitalização tende a ser mais grave do que o inverso.

Espera-se, como resultado, obter um modelo capaz de discriminar, com desempenho estatisticamente superior a classificadores triviais ou aleatórios, pacientes com maior propensão à hospitalização a partir de variáveis disponíveis no primeiro atendimento. Reconhece-se, que a evolução clínica da dengue é influenciada por fatores não capturados pelos dados disponíveis – como o tempo decorrido até a busca por atendimento e variações individuais na resposta imunológica –, de modo que não se pressupõe a obtenção de um modelo com desempenho preditivo absoluto, mas sim de uma ferramenta estatisticamente fundamentada, com potencial de subsidiar processos de triagem clínica e de gestão de recursos hospitalares.

5 Referências bibliográficas

Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde e Ambiente. *Sistema de Informação de Agravos de Notificação – Sinan: dados abertos, arboviroses – dengue*. Brasília: Ministério da Saúde, s.d. Disponível em: <<https://dadosabertos.saude.gov.br/dataset/arboviroses-dengue>>. Acesso em: 10 de setembro de 2026.

OLIVEIRA, W. *Validação do Painel de Arboviroses*. Fundação Butantan, s.d. Disponível em: <<https://epidemiologista.quarto.pub/relatorio-butantan/index.pdf>>. Acesso em: 10 de setembro de 2026.

PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011.